

Contrôle
Visualisation de données
(sans documents)

Exercice 1 : question de cours

Compléter le tableau ci-dessous pour caractériser chacune des méthodes vues en cours, en précisant le critère utilisé, et la nature de la méthode d'optimisation de ce critère.

	Critère	Méthode d'optimisation
<i>ACP</i>		
<i>LDA</i>		
<i>MDS</i>		
<i>Laplacian Eigenmaps</i>		
<i>t-SNE</i>		

Exercice 2 : Locally Linear Embedding

On rappelle que le principe de la méthode Locally Linear Embedding (LLE) est d'approcher chaque point $X_i \in \mathbb{R}^n$ par une combinaison linéaire de ses K plus proches voisins X_{ij} . Si l'on note \tilde{X}_i l'approximation de X_i et $w_i = (w_{i1} \dots w_{ik})^T$, alors on a la relation suivante

$$\tilde{X}_i = \sum_{j=1}^k w_{ij} X_{ij} \quad \text{avec} \quad \sum_{j=1}^k w_{ij} = 1_k^T w_i = 1 \quad (1)$$

et l'erreur d'approximation totale des m points X_i s'écrit

$$\min_{w_1, w_i, \dots, w_m} \sum_i \left\| X_i - \sum_{j=1}^k w_{ij} X_{ij} \right\|^2 \quad (2)$$

On cherche alors les points projetés $Y_i \in \mathbb{R}^d$ avec $d < n$, qui satisfont la même contrainte d'approximation par les K plus proches voisins Y_{ij} dans l'espace projeté, c'est à dire les Y_i qui minimisent l'erreur suivante

$$\min_{Y_1, Y_i, \dots, Y_m} \sum_i \left\| Y_i - \sum_{j=1}^k w_{ij} Y_{ij} \right\|^2 \quad (3)$$

Question 1 :

Si l'on note $N_i = (X_{i1} \dots X_{ik})$ la matrice de dimension (n, k) contenant les K plus proches voisins de X_i , **montrez que la relation suivante est vérifiée, et donner l'expression de G_i**

$$\varepsilon_i = \left\| X_i - \sum_{j=1}^k w_{ij} X_{ij} \right\|^2 = w_i^T G_i w_i \quad (4)$$

Question 2 :

On détermine les vecteurs de poids w_i qui minimisent l'erreur d'approximation ε_i sous la contrainte $1_k^T w_i = 1$. Si l'on note λ_i le multiplicateur de Lagrange associé à cette contrainte, alors on doit minimiser le Lagrangien suivant

$$\mathcal{L}_i = w_i^T G_i w_i + \lambda_i (1 - 1_k^T w_i) \quad (5)$$

En dérivant par rapport à w_i , **montrer que**

$$w_i = \frac{1}{2} G_i^{-1} \lambda_i \mathbf{1}_k \quad (6)$$

En introduisant la contrainte $\mathbf{1}_k^T w_i = 1$, **déduire que**

$$\lambda_i = \frac{2}{\mathbf{1}_k^T G_i^{-1} \mathbf{1}_k} \quad (7)$$

Déduire de 6) et 7) l'expression finale des vecteurs w_i ci-dessous

$$w_i = \frac{G_i^{-1} \mathbf{1}_k}{\mathbf{1}_k^T G_i^{-1} \mathbf{1}_k} \quad (8)$$

Question 3 :

On cherche maintenant à déterminer les points projetés Y_i en minimisant l'expression (3). On montre que cette expression peut s'écrire

$$\sum_i \|Y^T \mathbf{1}_i - Y^T \tilde{w}_i\|^2 = \|Y^T (I - \tilde{W}^T)\|_F^2 \quad (9)$$

Donner l'expression, et préciser la dimension des matrices et vecteurs ci-dessous

$$Y^T \quad \mathbf{1}_i \quad \tilde{w}_i \quad \tilde{W}^T$$

Question 4 :

On note M la matrice ci-dessous

$$M = (I - \tilde{W}^T)^T (I - \tilde{W}^T) \quad (10)$$

Préciser la dimension de cette matrice

Les points Y_i rassemblés dans la matrice Y , qui minimisent l'expression (9) sous les contraintes $\frac{1}{m} Y^T Y = I$, $Y^T \mathbf{1}_m = \mathbf{0}_d$, sont déduits des vecteurs propres de la matrice M .

Préciser la dimension de chaque vecteur propre de M .

Combien y en a-t-il au maximum ?

En excluant celui de valeur propre nulle, quels sont les vecteurs propres qu'il faut retenir pour minimiser le critère lorsque que l'espace projeté recherché est de dimension d ?

Question 5 :

On se place maintenant dans la situation où l'on cherche à exploiter les résultats de la méthode LLE optimisée sur un premier ensemble de points, pour déduire les projections de nouveaux points sans procéder à un réapprentissage.

Chaque nouveau point $X^t \in \mathbb{R}^n$ n'appartenant pas à l'ensemble d'apprentissage est projeté en $Y^t \in \mathbb{R}^d$ en exploitant uniquement les points $X_i, i = 1, \dots, m$ de l'ensemble d'apprentissage et leurs projections Y_i déterminées lors de l'apprentissage.

Proposer une méthode pour déterminer $Y^t \in \mathbb{R}^d$, et en préciser les étapes de calcul.